

TRƯỜNG ĐẠI HỌC NAM CẦN THƠ
TRƯỜNG CÔNG NGHỆ SỐ VÀ TRÍ TUỆ NHÂN TẠO



BÁO CÁO THỰC TẬP
NGHIÊN CỨU GIẢI THUẬT KNN NÂNG CAO
VỚI ENERGY-BASED DISTANCE

Họ và tên sinh viên: Huỳnh Đặng Nhu Cương

Mã số SV: 220851

Lớp: DH22TIN02

Ngành: Công Nghệ Thông Tin

Họ và tên giảng viên hướng dẫn: ThS. Trương Hùng Chen

Họ và tên cán bộ hướng dẫn tại nơi thực tập: KS. Võ Khương Duy

Cần Thơ, tháng 06 năm 2026

TRƯỜNG ĐẠI HỌC NAM CẦN THƠ
TRƯỜNG CÔNG NGHỆ SỐ VÀ TRÍ TUỆ NHÂN TẠO



HUỖNH ĐẶNG NHU CƯƠNG

MSSV: 220851

LỚP: DH22TIN02

TÊN ĐỀ TÀI

**NGHIÊN CỨU GIẢI THUẬT KNN NÂNG CAO
VỚI ENERGY-BASED DISTANCE**

Ngành: Công Nghệ Thông Tin

Mã số ngành: 7480201

GIẢNG VIÊN HƯỚNG DẪN

THS. TRƯỜNG HÙNG CHEN

GIẢNG VIÊN PHẢN BIỆN

THS. VÕ HOÀNG PHÚC

LỜI CẢM ƠN

Với lòng biết ơn sâu sắc và tình cảm chân thành em xin gửi lời cảm ơn tới:

Trường Đại học Nam Cần Thơ, trường Chuyển đổi số và Trí tuệ nhân tạo, cùng các giảng viên đã tận tình chỉ dạy và tạo điều kiện giúp đỡ em trong quá trình học tập, nghiên cứu.

Đặc biệt, em xin gửi lời cảm ơn đến thầy **ThS. Trương Hùng Chen**, giảng viên hướng dẫn, đã tận tình hướng dẫn, chỉ bảo, hỗ trợ và động viên em trong suốt quá trình thực tập và nghiên cứu đề tài.

Xin gửi lời cảm ơn đến những thầy cô đang công tác và giảng dạy tại Trường Đại học Nam Cần Thơ và một số thầy cô khác đã tận tình truyền đạt kiến thức quý báu, hỗ trợ cho em trong những năm vừa qua.

Em cũng xin gửi lời cảm ơn đến **KS. Võ Khương Duy**, cán bộ hướng dẫn tại Công ty TNHH MTV Công Nghệ Kỹ Thuật Tiên Phong, đã trực tiếp hướng dẫn, cung cấp môi trường thực hành và chia sẻ kinh nghiệm thực tế quý báu, giúp em hoàn thành tốt nhiệm vụ được giao.

Xin gửi lời cảm ơn đến quý thầy cô đang giảng dạy tại Trường Đại học Nam Cần Thơ đã truyền đạt kiến thức quý báu trong suốt những năm qua, là nền tảng vững chắc để em áp dụng vào thực tiễn.

Mặc dù đã cố gắng rất nhiều nhưng do kiến thức còn hạn chế nên không tránh khỏi những thiếu sót trong quá trình thực hiện đề tài. Vì thế, rất mong nhận được những ý kiến đóng góp của quý thầy cô, để em có thêm những kinh nghiệm và rút ra bài học quý báu cho những công việc chuyên môn của em về sau này.

Em xin chân thành cảm ơn! Trân trọng.

Cần Thơ, ngày tháng năm 2026

Người thực hiện

Huỳnh Đặng Nhu Cường

PHIẾU ĐÁNH GIÁ BÁO CÁO KẾT QUẢ THỰC TẬP

Học kỳ III năm học 2025-2026

(Dùng cho giảng viên chấm báo cáo thực tập - tối đa 6 điểm)

Họ và tên giảng viên Hướng dẫn: ThS. Trương Hùng Chen

Họ tên sinh viên thực tập: Huỳnh Đặng Nhu Cương

Mã số SV: 220851

Lớp: DH22TIN02

Ngành: Công Nghệ Thông Tin

Nội dung đánh giá	Điểm tối đa	Điểm chấm
I. Hình thức trình bày	0.5	
I.1 Đúng format của Khoa: Trang bìa, trang lời cảm ơn, 02 trang đánh giá thực tập của GVHD và GVPB (mẫu M-TT-04), trang tổng hợp điểm (M-TT-05), trang mục lục và các nội dung báo cáo. Sử dụng đúng mã và font tiếng Việt (Unicode Times New Roman, Size 13)	0.25	
I.2 Trình bày mạch lạc, súc tích, không có lỗi chính tả	0.25	
II. Phiếu theo dõi	0.5	
II.1 Có lịch làm việc đầy đủ cho 8 tuần	0.25	
II.2 Số buổi thực tập tại cơ quan trong 1 tuần ≥ 6 ; ít hơn 6 buổi 0.0 điểm	0.25	
III. Nội dung thực tập (quyển báo cáo)	3.0	
- Có được sự hiểu biết tốt về cơ quan nơi thực tập.	0.5	
- Phương pháp thực hiện phù hợp với nội dung công việc được giao.	0.5	
- Kết quả củng cố lý thuyết.	0.5	
- Kết quả rèn luyện kỹ năng thực hành.	0.5	
- Kinh nghiệm thực tiễn thu nhận được.	0.5	
- Kết quả công việc có đóng góp cho cơ quan nơi thực tập	0.5	
IV. Kết quả chất vấn sinh viên	2.0	
TỔNG CỘNG	6.0	
Điểm trừ		
Điểm còn lại		

Cần Thơ, ngày....tháng....năm 2026

GIẢNG VIÊN CHẤM BÁO CÁO

PHIẾU ĐÁNH GIÁ BÁO CÁO KẾT QUẢ THỰC TẬP

Học kỳ III năm học 2025-2026
(Dùng cho giảng viên chấm báo cáo thực tập - tối đa 6 điểm)

Họ và tên giảng viên Phản biện: ThS. Võ Văn Phúc

Họ tên sinh viên thực tập: Huỳnh Đặng Nhu Cương

Mã số SV: 220851

LớpDH22TIN02

Ngành: Công Nghệ Thông Tin

Nội dung đánh giá	Điểm tối đa	Điểm chấm
I. Hình thức trình bày	0.5	
I.1 Đúng format của Khoa: Trang bìa, trang lời cảm ơn, 02 trang đánh giá thực tập của GVHD và GVPB (mẫu M-TT-04), trang tổng hợp điểm (M-TT-05), trang mục lục và các nội dung báo cáo. Sử dụng đúng mã và font tiếng Việt (Unicode Times New Roman, Size 13)	0.25	
I.2 Trình bày mạch lạc, súc tích, không có lỗi chính tả	0.25	
II. Phiếu theo dõi	0.5	
II.1 Có lịch làm việc đầy đủ cho 8 tuần	0.25	
II.2 Số buổi thực tập tại cơ quan trong 1 tuần ≥ 6 ; ít hơn 6 buổi 0.0 điểm	0.25	
III. Nội dung thực tập (quyển báo cáo)	3.0	
- Có được sự hiểu biết tốt về cơ quan nơi thực tập.	0.5	
- Phương pháp thực hiện phù hợp với nội dung công việc được giao.	0.5	
- Kết quả củng cố lý thuyết.	0.5	
- Kết quả rèn luyện kỹ năng thực hành.	0.5	
- Kinh nghiệm thực tiễn thu nhận được.	0.5	
- Kết quả công việc có đóng góp cho cơ quan nơi thực tập	0.5	
IV. Kết quả chất vấn sinh viên	2.0	
TỔNG CỘNG	6.0	
Điểm trừ		
Điểm còn lại		

Cần Thơ, ngày....tháng....năm 2026

GIẢNG VIÊN CHẤM BÁO CÁO

PHIẾU ĐIỂM TỔNG HỢP KẾT QUẢ THỰC TẬP
Học kỳ III năm học 2025-2026
(Dùng cho giảng viên Hướng dẫn tổng hợp - tối đa 10 điểm)

Họ và tên giảng viên Hướng dẫn: ThS. Trương Hùng Chen
Mã số SV: 220851
Họ tên sinh viên thực tập: Huỳnh Đặng Nhu Cương
Ngành: Công Nghệ Thông Tin
LớpDH22TIN02

Nguồn điểm	Điểm
1. Điểm của cán bộ hướng dẫn tại nơi thực tập (A)	
2. Điểm của giảng viên hướng dẫn (B)	
3. Điểm của giảng viên phản biện (C)	
Điểm tổng hợp= $A+(B+C)/2$ (làm tròn tới 1 chữ số thập phân)	

Cần Thơ, ngày....tháng....năm 2026
GIẢNG VIÊN HƯỚNG DẪN

Trang phiếu giao việc (bản gốc, có chữ ký của cán bộ hướng dẫn và xác nhận của cơ quan nơi thực tập).

MỤC LỤC

CHƯƠNG 1: TỔNG QUAN VỀ ĐƠN VỊ THỰC TẬP.....	5
1.1 GIỚI THIỆU CÔNG TY	5
1.2 THÔNG TIN VỀ CÔNG TY	6
1.3 TRỤ SỞ CHÍNH.....	6
1.4 NGƯỜI ĐẠI DIỆN THEO PHÁP LUẬT	6
1.5 THÔNG TIN LIÊN HỆ	6
CHƯƠNG 2: NỘI DUNG CÔNG VIỆC ĐƯỢC PHÂN CÔNG	7
2.1 CÁC CÔNG VIỆC ĐƯỢC GIAO	7
2.2 CÁC GIAI ĐOẠN THỰC HIỆN	8
2.2.1 Giai đoạn 1: Xây dựng nền tảng hạ tầng thực nghiệm.....	8
2.2.2 Giai đoạn 2: Phát triển hệ thống lõi và tích hợp AI	8
2.2.3 Giai đoạn 3: Nghiên cứu và triển khai đề tài đề xuất	8
CHƯƠNG 3: PHƯƠNG PHÁP THỰC HIỆN	9
3.1 CƠ SỞ KHOA HỌC CỦA GIẢI THUẬT	9
3.1 Bài toán Phát hiện Bất thường Dữ liệu (Anomaly Detection).....	9
3.1.2 Giải thuật KNN chuẩn và hạn chế	9
3.1.3 Energy-based Distance - Hàm khoảng cách năng lượng.....	10
3.1.4 Mô hình KNN nâng cao với Energy-based Distance	11
3.2.1 Thu thập và phân tích tài liệu	13
3.2.2 Cài đặt và thực nghiệm giải thuật	13
3.2.3 Đánh giá và so sánh kết quả	13
CHƯƠNG 4: KẾT QUẢ ĐẠT ĐƯỢC QUA ĐỢT THỰC TẬP.....	14
TÀI LIỆU THAM KHẢO	21

DANH MỤC BẢNG

Bảng 4.1 Tóm tắt về 17 tập dữ liệu chuẩn được phân lớp theo Tỷ lệ mất cân bằng.....	14
Bảng 4.2 Kết quả so sánh giá trị F1-Score các phương pháp phát hiện bất thường trên các tập dữ liệu	15

DANH MỤC HÌNH

Hình 4.1 Giao diện nhập dữ liệu - cho phép upload file csv/xlsx.....	17
Hình 4.2 Giao diện cấu hình tham số K và ngưỡng phân loại.....	18
Hình 4.3 Giao diện kết quả - hiển thị tổng kết phân loại, biểu đồ phân phối điểm bất thường và các chỉ số AUROC, MCC. Cho phép xuất kết quả ra file csv	19
Hình 4.4 Giao diện Swagger UI của API FastAPI - mô tả các endpoint, tham số đầu vào / đầu ra của hệ thống EBD-KNN.....	20

CHƯƠNG 1: TỔNG QUAN VỀ ĐƠN VỊ THỰC TẬP

1.1 GIỚI THIỆU CÔNG TY

Công ty TNHH MTV Công Nghệ Kỹ Thuật Tiên Phong là một doanh nghiệp chuyên biệt trong lĩnh vực công nghệ và kỹ thuật tại Việt Nam, có trụ sở chính tại Thành phố Cần Thơ. Công ty được thành lập dựa trên nguyên lý cốt lõi là phát triển và triển khai các giải pháp công nghệ tiên tiến mang tính đột phá, đồng thời định hướng hoạt động theo hướng nghiên cứu hệ thống và ứng dụng thực tiễn.

Công ty chuyên cung cấp các sản phẩm và giải pháp công nghệ AI, bao gồm:

- Hệ thống nhận dạng giọng nói và chữ viết tay
- Hệ thống truy xuất thông tin
- Hệ thống phân tích dữ liệu lớn (Big Data)
- Giải pháp dự đoán và điều khiển thông minh

Ngoài ra, công ty còn phát triển các ứng dụng trên nhiều nền tảng như máy tính, thiết bị di động và IoT, sử dụng các thuật toán tiên tiến để mang đến giải pháp tối ưu cho khách hàng. Sản phẩm của công ty được ứng dụng rộng rãi trong nhiều lĩnh vực như y tế, tài chính, bán lẻ, giáo dục... giúp khách hàng nâng cao năng suất, cải thiện chất lượng dịch vụ và tối ưu hóa chi phí.

Các dự án tiêu biểu:

- AISol (Artificial Intelligence Solutions): Bộ giải pháp AI toàn diện, ứng dụng trong nhiều lĩnh vực như kinh tế, y tế, xã hội, nông nghiệp, dịch vụ và chuỗi cung ứng.
- LTCM (LithoTherapy Calculating Machine): Hệ thống đo năng lượng khoáng vật và đá quý, đã được thử nghiệm tại các trung tâm ngọc học và nghiên cứu khoáng vật.
- EntRobot (Entertainment Robot): Dự án robot giải trí với nhiều dòng sản phẩm như dRobot (robot chó), fRobot (robot bạn bè), mRobot (robot marketing), eRobot (robot giáo dục).

Song song với việc phát triển sản phẩm, công ty cũng cung cấp dịch vụ tư vấn và đào tạo AI cho các tổ chức, doanh nghiệp. Với đội ngũ nhân sự chuyên nghiệp, giàu kinh nghiệm và định hướng phát triển bền vững, Công ty TNHH MTV Công Nghệ Kỹ Thuật Tiên Phong đã thiết lập vị thế đáng tin cậy trong hệ sinh thái đổi mới cả trong và ngoài nước.

1.2 THÔNG TIN VỀ CÔNG TY

- Tên công ty tiếng Việt: Công Ty TNHH MTV Công Nghệ Kỹ Thuật Tiên Phong
- Tên công ty viết bằng tiếng Anh: ADVANCED HIGH TECHNOLOGY ONE MEMBER LIMITED LIABILITY COMPANY
- Tên công ty viết tắt: ADHIGHTECH
- Mã số thuế: 1801526082
- Loại hình kinh doanh: Nghiên cứu và phát triển công nghệ, Sản xuất và cung cấp thiết bị kỹ thuật, Dịch vụ tư vấn và giải pháp công nghệ.

1.3 TRỤ SỞ CHÍNH

Số B16, đường số 08, khu dân cư Công Ty 8, Phường Phú Thứ, Quận Cái Răng, Thành phố Cần Thơ.

1.4 NGƯỜI ĐẠI DIỆN THEO PHÁP LUẬT

Họ và tên (ghi bằng chữ in hoa): NGÔ HỒ ANH KHÔI

Ngoài ra NGÔ HỒ ANH KHÔI còn đại diện các doanh nghiệp:

Founder, Director, CEO tại Shamanism Museum - Bảo Tàng Vu Thuật.

Founder tại Museum of Tarot and Oracle.

Founder and Researcher tại Hội Tarot Huyền Bí.

1.5 THÔNG TIN LIÊN HỆ

Địa chỉ: Số B16, đường số 08, khu dân cư Công Ty 8, Phường Phú Thứ, Quận Cái Răng, Thành phố Cần Thơ.

Điện thoại: 0353220302

Email: nhakhoy@nctu.edu.vn

Website công ty: <https://www.adhigtechn.com/>

CHƯƠNG 2: NỘI DUNG CÔNG VIỆC ĐƯỢC PHÂN CÔNG

2.1 CÁC CÔNG VIỆC ĐƯỢC GIAO

- Tìm hiểu Git/GitHub; Workflow (add, commit, pull, push..) - Cách cấu hình Git cho các nền tảng Python, Node.js, PHP - Tạo repository theo yêu cầu
- Cài đặt Python, cấu hình môi trường ảo venv - Cài đặt PHP, composer và thực hiện khởi tạo các dự án mẫu - Khảo sát, so sánh và báo cáo về MySQL và SQLite
- Cài đặt Flutter SDK và cấu hình môi trường trên VS Code/Android Studio) - Tạo và chạy dự án mẫu
- Tìm hiểu về thị trường LLM, trên 3 nền tảng: OpenAI, Google Gemini, Grok - Thực hiện quy trình lấy API Key - Soạn báo cáo so sánh giữa 3 nền tảng: OpenAI, Google Gemini, Grok
- Tìm hiểu về langchain, langchain load documents, langchain embedding, langchain faiss - Thử nghiệm kết nối LangChain với API Key - Thực hành Agent và tool cơ bản
- Tìm hiểu về Vector Database (FAISS, Pinecone, ChromaDB) - Tìm hiểu về quy trình Embedding và Semantic Search - Tìm hiểu về cách triển khai Proxmox
- Chuẩn hoá code theo cấu trúc API: https://github.com/duyvo26/api_base_public - Tích hợp (LLM, model) vào API. - Tìm kiếm giao diện cho web. - Kiểm tra cấu trúc code (python có sử dụng virtual environments, .env, cấu trúc python 3.10.?).
Nghiên cứu và triển khai đề tài: Giải thuật KNN nâng cao với Energy-based Distance; Kiểm tra, đánh giá, so sánh giải thuật đề xuất và các baselines.

2.2 CÁC GIAI ĐOẠN THỰC HIỆN

2.2.1 Giai đoạn 1: Xây dựng nền tảng hạ tầng thực nghiệm

Để thuật toán AI chạy ổn định và đo lường khách quan, một môi trường thực nghiệm chuẩn đã được thiết lập trong tuần đầu tiên:

Thiết lập máy chủ ảo hóa (Proxmox & aaPanel): Cài đặt và cấu hình Proxmox để tạo các máy ảo (VM) và Container cô lập. Sử dụng aaPanel để trực quan hóa quản trị server, quản lý port, network, mô phỏng chính xác điều kiện triển khai thực tế.

Quản trị môi trường Python: Cấu hình Virtual Environment (venv), quản lý các thư viện tính toán khoa học (NumPy, SciPy, Scikit-learn). Môi trường này đảm bảo dependency không bị xung đột khi thực thi các phép toán ma trận phức tạp của giải thuật KNN trên server.

2.2.2 Giai đoạn 2: Phát triển hệ thống lõi và tích hợp AI

Hệ thống được thiết kế bài bản để làm cầu nối giữa dữ liệu đầu vào và nhân thuật toán:

Xây dựng nền tảng API Base: Phát triển hệ thống API tuân thủ kiến trúc 3 lớp (3-layer architecture): Presentation Layer (tiếp nhận request, xác thực), Process Layer (xử lý logic nghiệp vụ, gọi module KNN), Database Layer (giao tiếp CSDL).

Tích hợp LLM & Vector Database: Nghiên cứu framework LangChain và Vector Database (FAISS, ChromaDB) để xử lý, biểu diễn dữ liệu dưới dạng embedding vector, chuẩn bị đầu vào có cấu trúc tối ưu cho thuật toán tính khoảng cách

2.2.3 Giai đoạn 3: Nghiên cứu và triển khai đề tài đề xuất

Công việc cốt lõi của kỳ thực tập là R&D giải thuật KNN nâng cao kết hợp hàm khoảng cách năng lượng (Energy-based Distance) phục vụ bài toán phát hiện bất thường dữ liệu (Anomaly Detection).

Tiến độ công việc được ghi nhận và báo cáo định kỳ cho Mentor thông qua các buổi họp báo cáo tiến độ minh chứng từng giai đoạn, từ lúc dựng server đến khi API trả về kết quả dự đoán.

CHƯƠNG 3: PHƯƠNG PHÁP THỰC HIỆN

3.1 CƠ SỞ KHOA HỌC CỦA GIẢI THUẬT

3.1.1 Bài toán Phát hiện Bất thường Dữ liệu (Anomaly Detection)

Phát hiện bất thường (Anomaly Detection hay Outlier Detection) là bài toán trọng tâm trong khai phá dữ liệu, nhằm xác định các điểm dữ liệu, chuỗi sự kiện hoặc quan sát có hành vi hoặc sự phân phối sai lệch đáng kể so với phần lớn dữ liệu thông thường (inliers). Những điểm dữ liệu sai lệch này được gọi là các điểm bất thường (anomalies hoặc outliers) và chúng thường mang những thông tin quan trọng, báo hiệu sự cố, hành vi gian lận hoặc sự thay đổi cấu trúc trong hệ thống thực tế (Aggarwal, 2017; Chandola et al., 2009).

Theo Goldstein và Uchida (2016), các phương pháp phát hiện bất thường có thể được phân loại thành nhiều nhóm khác nhau dựa trên cách thức tiếp cận và định nghĩa về sự bất thường. Trong đó, hai nhóm phương pháp nền tảng và phổ biến nhất bao gồm:

- **Phương pháp dựa trên thống kê (Statistical-based methods):** Giả định rằng dữ liệu bình thường tuân theo một phân phối thống kê nhất định (ví dụ: phân phối chuẩn Gauss). Các điểm dữ liệu có xác suất xuất hiện thấp theo mô hình phân phối này sẽ được đánh dấu là bất thường.
- **Phương pháp dựa trên khoảng cách và mật độ (Distance/Density-based methods):** Không yêu cầu các giả định ngặt nghèo về phân phối tham số của dữ liệu. Phương pháp này đánh giá sự bất thường của một điểm thông qua khoảng cách hình học của nó so với các điểm lân cận (như K-Nearest Neighbors) hoặc so sánh mật độ cục bộ của điểm đó với các điểm xung quanh (như thuật toán Local Outlier Factor - LOF) (Breunig et al., 2000).

Trong bối cảnh đề tài này, cách tiếp cận dựa trên khoảng cách được ưu tiên lựa chọn do tính linh hoạt, khả năng giải thích cao và không bị phụ thuộc vào các tham số phân phối tiên nghiệm của dữ liệu.

3.1.2 Giải thuật KNN chuẩn và hạn chế

Nguyên lý hoạt động cơ bản của KNN trong phát hiện bất thường Giải thuật K-Nearest Neighbors (KNN) được Ramaswamy et al. (2000) giới thiệu như một phương pháp mạnh mẽ để khai phá các điểm bất thường dựa trên khoảng cách. Ý tưởng cốt lõi của giải thuật này là: một điểm dữ liệu nằm càng xa các điểm láng giềng gần nhất của nó thì khả năng nó là một điểm bất thường càng cao.

Cụ thể, với một tập dữ liệu X , điểm bất thường (anomaly score) của một quan sát $x \in X$ có thể được định nghĩa bằng trung bình khoảng cách từ x đến K điểm láng giềng gần nhất của nó:

$$score(x) = \frac{1}{K} \sum_{i=1}^K d(x, x_i)$$

Trong đó:

- K là số lượng điểm láng giềng được xét.
- x_i là điểm láng giềng gần thứ i của x .
- $d(x, x_i)$ là hàm tính khoảng cách giữa hai điểm (thông thường sử dụng khoảng cách Euclidean).

Các quan sát có điểm số $score(x)$ vượt qua một ngưỡng θ nhất định sẽ được mô hình gán nhãn là bất thường.

Hạn chế: Lỗi nguyên chiều cao (Curse of Dimensionality) Mặc dù trực quan và dễ triển khai, giải thuật KNN truyền thống dựa trên khoảng cách Euclidean đối mặt với một rào cản toán học nghiêm trọng khi xử lý dữ liệu thực tế: "Lỗi nguyên chiều cao".

Theo Beyer et al. (1999), khi số lượng đặc trưng (số chiều của dữ liệu) tăng lên, hiện tượng "tập trung khoảng cách" (distance concentration) sẽ xảy ra. Điều này có nghĩa là sự khác biệt giữa khoảng cách lớn nhất và khoảng cách nhỏ nhất từ một điểm đến các điểm khác trong không gian tiệm cận về 0:

$$\lim_{d \rightarrow \infty} \frac{D_{max} - D_{min}}{D_{min}} = 0$$

Khi hiện tượng này xảy ra, các điểm láng giềng gần nhất và xa nhất có khoảng cách gần như bằng nhau. Khoảng cách hình học thuần túy (như Euclidean hay Manhattan) mất đi ý nghĩa phân biệt. Do đó, KNN truyền thống thất bại trong việc xác định các điểm bất thường trong không gian dữ liệu phức tạp nhiều chiều.

3.1.3 Energy-based Distance - Hàm khoảng cách năng lượng

Để khắc phục rào cản của hình học Euclid trong không gian nhiều chiều, Thống kê Năng lượng (Energy Statistics) đã cung cấp một góc nhìn mới. Székely và Rizzo (2013) đã phát triển khái niệm Khoảng cách Năng lượng (Energy-based Distance - EBD) lấy cảm hứng từ thế năng hấp dẫn của Newton trong vật lý thống kê.

Thay vì chỉ đo lường sự khác biệt về mặt tọa độ hình học giữa hai điểm, EBD đo lường mức độ sai biệt thống kê và sự "không tương thích" về mặt phân phối giữa chúng. Khoảng cách năng lượng giữa hai điểm x và y được định nghĩa qua kỳ vọng toán học:

$$E(x, y) = 2\mathbb{E}[\|x - y\|] - \mathbb{E}[\|x - x'\|] - \mathbb{E}[\|y - y'\|]$$

Trong đó:

- $\|\cdot\|$ là chuẩn vector (thường là chuẩn L2).
- x' và y' là các mẫu phân phối độc lập cùng loại (independent identically distributed - i.i.d) tương ứng với môi trường cục bộ của x và y .

Ưu điểm vượt trội của EBD:

- Chống lại Lỗi nguyên chiều cao: Bằng cách trừ đi khoảng cách nội tại (kỳ vọng khoảng cách giữa các mẫu trong cùng một cụm $E\|x - x'\|$ và $E\|y - y'\|$, EBD tự động triệt tiêu các nhiễu độ đo sinh ra trong không gian nhiều chiều.
- Tính phi tham số (Non-parametric): Hàm EBD không yêu cầu bất kỳ định dạng trước nào về sự phân phối của dữ liệu, làm cho nó phù hợp với mọi cấu trúc dữ liệu đa tạp.
- Tính ổn định (Positive semi-definite): EBD luôn duy trì tính chất bán định dương, đảm bảo các ma trận khoảng cách phục vụ cho giải thuật KNN luôn khả nghịch và ổn định khi tính toán bằng các thư viện như SciPy, NumPy.

3.1.4 Mô hình KNN nâng cao với Energy-based Distance

Nhằm tối ưu hóa năng lực phát hiện bất thường, đề tài này đề xuất và triển khai kiến trúc EBD-KNN. Quá trình tính toán được thực hiện một cách tự động, linh hoạt với kích thước của mọi tập dữ liệu thực tế mà không bị ràng buộc bởi các giới hạn lấy mẫu cứng (hardcoded sampling limits) theo các bước cụ thể sau:

- Bước 1: Tiền xử lý dữ liệu - dữ liệu đầu vào, sau khi được loại bỏ các giá trị khuyết thiếu, sẽ được chuẩn hóa thông qua StandardScaler (Z-score normalization) hoặc MinMaxScaler để đảm bảo các đặc trưng đa chiều cùng nằm trên một thang đo thống nhất, tránh hiện tượng các đặc trưng có giá trị lớn chi phối hàm khoảng cách.
- Bước 2: Tính ma trận khoảng cách Energy-based giữa tất cả các cặp điểm trong tập huấn luyện. Thay vì dùng hình học chuẩn, hệ thống tự động trích

xuất cấu trúc tập dữ liệu và tính toán hàm kỳ vọng EBD giữa toàn bộ các cặp quan sát trong không gian đặc trưng. Quy trình tính toán kỳ vọng E sẽ được hệ thống quét động (dynamic adapt) trên toàn bộ kích thước của tập dữ liệu thực thay vì giới hạn số mẫu lấy trước, đảm bảo sự toàn vẹn của phân phối thống kê.

- Bước 3: Với mỗi quan sát x cần kiểm tra, thuật toán tra cứu ma trận EBD để tìm ra K điểm láng giềng có "khoảng cách năng lượng" nhỏ nhất. Điểm bất thường (Anomaly Score) được tính bằng trung bình khoảng cách năng lượng đến K điểm láng giềng này.
- Bước 4: Ngưỡng phân định θ không được chọn cố định mà được xác định tự động bằng phân vị thứ p của sự phân phối điểm bất thường toàn cục, hoặc thông qua phương pháp Z-score của độ lệch dư, từ đó dán nhãn linh hoạt cho dữ liệu mới.
- Bước 5: Đánh giá mô hình - kết quả phân loại cuối cùng được đối soát tự động thông qua ma trận nhầm lẫn (Confusion Matrix). Mô hình được đánh giá nghiêm ngặt qua các chỉ số cân bằng bao gồm Diện tích dưới đường cong ROC (AUROC), Hệ số tương quan Matthews (MCC) và pAUROC để đo lường năng lực phân biệt chính xác trong bài toán mất cân bằng lớp trầm trọng.

3.2 QUY TRÌNH THỰC HIỆN HỆ THỐNG THỰC TIỄN

3.2.1 Thu thập và phân tích tài liệu

Tìm kiếm và tổng hợp các bài báo nghiên cứu từ các nguồn uy tín (IEEE, arXiv, Springer) liên quan đến: Anomaly Detection, Energy Distance, và KNN variants. Các tập dữ liệu benchmark chuẩn trên UCI.

3.2.2 Cài đặt và thực nghiệm giải thuật

Giải thuật EBD-KNN được cài đặt hoàn toàn bằng Python 3.10 với các thư viện: NumPy, SciPy (tính Energy Distance), Scikit-learn (KNN cơ bản, pipeline chuẩn hóa), và Pandas (tiền xử lý dữ liệu). Toàn bộ thực nghiệm chạy trong môi trường Virtual Environment (venv).

3.2.3 Đánh giá và so sánh kết quả

Kết quả của EBD-KNN được đánh giá và so sánh với các baseline: KNN chuẩn (Euclidean), LOF (Local Outlier Factor) và Isolation Forest. Các độ đo đánh giá bao gồm AUROC (Area Under ROC Curve), MCC (Matthews Correlation Coefficient) và pAUROC (partial AUROC).

3.2.4 Xây dựng giao diện và tích hợp API

Sau khi giải thuật hoạt động ổn định, hệ thống được đóng gói thành API endpoint FastAPI và tích hợp vào giao diện web demo, cho phép người dùng nhập dữ liệu và nhận kết quả phân loại theo thời gian thực.

CHƯƠNG 4: KẾT QUẢ ĐẠT ĐƯỢC QUA ĐỢT THỰC TẬP

4.1 KIẾN THỨC LÝ THUYẾT ĐƯỢC Củng cố và BỔ SUNG

Hạ tầng & DevOps: Hiểu sâu sắc mối liên hệ hữu cơ giữa hạ tầng hệ thống (Server/DevOps) và trí tuệ nhân tạo (AI/ML). Một giải thuật AI tốt cần môi trường ảo hóa chuẩn (Proxmox/Container) để phát huy hiệu quả.

Toán học & AI: Nắm vững cơ sở toán thống kê của Vector Database, Semantic Search và hàm khoảng cách năng lượng. Hiểu cách Energy Distance vượt qua giới hạn của Euclidean Distance trong không gian đa chiều.

Hệ thống LLM: Hiểu rõ kiến trúc và cách vận hành của các mô hình ngôn ngữ lớn (OpenAI GPT, Google Gemini, Grok), quy trình lấy và quản lý API Key an toàn.

Vector Database: Nắm được quy trình Embedding và Semantic Search với FAISS, Pinecone, ChromaDB; hiểu cách biểu diễn dữ liệu ngữ nghĩa trong không gian vector.

4.2 KỸ NĂNG THỰC HÀNH HỌC HỎI ĐƯỢC

Kỹ năng DevOps & Fullstack: Có khả năng thiết lập môi trường phát triển tách biệt giữa Frontend và Backend, tích hợp giao tiếp API giữa hai tầng, và quản lý phiên bản mã nguồn bằng Git.

Kỹ năng R&D và tối ưu mã: Chuyển hóa công thức toán học học thuật thành mã nguồn Python có tính thực thi cao, áp dụng Clean Code, PEP8, Git workflow để làm việc theo chuẩn doanh nghiệp.

Kỹ năng tích hợp hệ thống: Xây dựng REST API với FastAPI, kết nối frontend-backend, quản lý dependency với requirements.txt và file .env bảo mật.

4.3 KINH NGHIỆM THỰC TIỄN TÍCH LŨY ĐƯỢC

Tư duy bảo mật: Nâng cao ý thức bảo mật trong môi trường doanh nghiệp qua việc quản lý cấp phép địa chỉ MAC, mã hóa API Key trong file .env, không commit secret lên Git.

Vòng đời phần mềm: Trải nghiệm toàn bộ vòng đời từ nhận yêu cầu, nghiên cứu lý thuyết, viết code, đến đóng gói dự án, backup dữ liệu, viết tài liệu kỹ thuật (Docstring/README) và làm Video Demo nghiệm thu.

Kỹ năng mềm & giao tiếp: Rèn luyện khả năng báo cáo tiến độ công việc định kỳ, trình bày vấn đề rõ ràng, súc tích, và chủ động trao đổi khi gặp khó khăn trong quá trình thực hiện dự án.

4.4 CHI TIẾT CÁC KẾT QUẢ CÔNG VIỆC ĐÓNG GÓP CHO CÔNG TY

4.4.1 Kết quả thực nghiệm giải thuật EBD-KNN

Giải thuật EBD-KNN đã được triển khai thành công và kiểm thử trên tập dữ liệu benchmark. Kết quả cho thấy sự cải tiến rõ rệt về độ chính xác so với các phương pháp baseline truyền thống.

Bảng 4.1 Kết quả so sánh giá trị F1-Score các phương pháp phát hiện bất thường trên các tập dữ liệu


Dataset	IR	E/ L_2	KNN $-L_2$	KNN $-L_1$	KNN $-Chb$	KNN $-Mk$	KNN- Cos
<i>Tier 1 - Balanced ($IR \leq 1.5$)</i>							
image segmentation	1.00	0.85	0.85	0.90	0.78	0.85	0.86
iris	1.00	0.95	0.97	0.95	0.94	0.97	0.89
wine	1.48	0.98	0.97	0.98	0.95	0.97	0.97
<i>Tier 2 - Mildly Imbalanced ($1.5 < IR \leq 5$)</i>							
breast_cancer_wisc	1.68	0.97	0.97	0.97	0.94	0.97	0.96
contraceptive_method	1.89	0.44	0.50	0.51	0.50	0.51	0.50
haberman_survival	2.78	0.59	0.61	0.58	0.61	0.60	0.58
ionosphere	1.79	0.87	0.85	0.89	0.86	0.82	0.88
<i>Tier 3 - Severely Imbalanced ($IR > 5$)</i>							
balance_scale	5.88	0.69	0.64	0.62	0.69	0.64	0.75
car_evaluation	18.6	0.64	0.52	0.52	0.26	0.28	0.53
cardiotocography	10.9	0.74	0.68	0.69	0.61	0.67	0.67
dermatology	5.60	0.97	0.97	0.98	0.93	0.96	0.97
ecoli	71.5	0.72	0.74	0.75	0.74	0.74	0.72
glass_identification	8.44	0.67	0.61	0.65	0.54	0.60	0.64
heart_disease	12.6	0.32	0.30	0.31	0.30	0.32	0.33
yeast	92.6	0.55	0.55	0.55	0.55	0.55	0.53

Bảng 4.2 Kết quả so sánh giá trị F1-Score các phương pháp phát hiện bất thường trên các tập dữ liệu


Dataset	IR	E/ L_2	E/ L_1	E/ Cos	KNN- L_2	KNN- L_1	KNN- Chb	KNN- Mk	KNN- Cos	KNN- W_t
Tier 1 - Balanced ($IR \leq 1.5$)										
Image Segmentati on	1.00	0.86	0.89	0.87	0.87	0.89	0.78	0.84	0.85	0.87
Iris	1.00	0.95	0.97	0.94	0.96	0.96	0.95	0.97	0.87	0.97
Waveform	1.03	0.80	0.81	0.82	0.86	0.86	0.84	0.85	0.83	0.86
Wine	1.48	0.98	0.98	0.99	0.97	0.98	0.95	0.96	0.98	0.97
Tier 2 - Mildly Imbalanced ($1.5 < IR \leq 5$)										
Breast Cancer Wisconsin	1.68	0.97	0.97	0.95	0.97	0.97	0.94	0.96	0.96	0.97
Ionosphere	1.79	0.86	0.91	0.90	0.86	0.89	0.85	0.82	0.88	0.83
Contracept ive Method	1.89	0.44	0.44	0.44	0.51	0.51	0.50	0.52	0.50	0.49
Vertebral Column	2.50	0.75	0.77	0.77	0.78	0.76	0.76	0.76	0.79	0.78
Haberman Survival	2.78	0.57	0.57	0.55	0.60	0.57	0.61	0.60	0.60	0.58
Tier 3 - Severely Imbalanced ($IR > 5$)										
Dermatolo gy	5.60	0.97	0.97	0.97	0.96	0.98	0.92	0.95	0.96	0.96
Balance Scale	5.88	0.68	0.68	0.74	0.64	0.62	0.66	0.64	0.69	0.63
Glass Identificati on	8.44	0.64	0.66	0.66	0.58	0.61	0.55	0.58	0.61	0.64
Cardiotoco graphy	10.92	0.74	0.74	0.74	0.68	0.69	0.62	0.67	0.67	0.72
Heart Disease	12.62	0.33	0.33	0.35	0.30	0.30	0.32	0.31	0.33	0.32
Car Evaluation	18.62	0.66	0.63	0.67	0.46	0.48	0.22	0.28	0.51	0.45
Yeast	92.60	0.54	0.53	0.52	0.55	0.54	0.54	0.54	0.53	0.56
Wine Quality	567.2 0	0.45	0.45	0.43	0.34	0.35	0.33	0.35	0.34	0.44

4.4.2 Giao diện Demo Web - Trang nhập dữ liệu và phân tích

Giao diện web demo được xây dựng với React, kết nối API FastAPI backend. Giao diện bao gồm 3 trang chức năng chính:




Hình 4.1 Giao diện nhập dữ liệu - cho phép upload file csv/xlsx



Hình 4.3 Giao diện kết quả - hiển thị tổng kết phân loại, biểu đồ phân phối điểm bất thường và các chỉ số AUROC, MCC. Cho phép xuất kết quả ra file csv

4.4.3 Giao diện API Documentation (Swagger UI)



Hình 4.4 Giao diện Swagger UI của API FastAPI - mô tả các endpoint, tham số đầu vào / đầu ra của hệ thống EBD-KNN

Toàn bộ hệ thống sẽ được đóng gói bằng Docker và upload lên hosting nội bộ của công ty, phục vụ cho các đánh giá nội bộ và làm nền tảng nghiên cứu tiếp theo cho nhóm R&D trong tương lai.

TÀI LIỆU THAM KHẢO

- [1]. Aggarwal, C. C. (2017). Outlier analysis (2nd ed.). Springer. <https://doi.org/10.1007/978-3-319-47578-3>
- [2]. Beyer, K., Goldstein, J., Ramakrishnan, R., & Shaft, U. (1999). When is "nearest neighbor" meaningful? In *Database Theory-ICDT'99: 7th International Conference* (pp. 217–235). Springer. https://doi.org/10.1007/3-540-49257-7_15
- [3]. Breunig, M. M., Kriegel, H.-P., Ng, R. T., & Sander, J. (2000). LOF: Identifying density-based local outliers. *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*, 93-104. <https://doi.org/10.1145/342009.335388>
- [4]. Chandola, V., Banerjee, A., & Kumar, V. (2009). Anomaly detection: A survey. *ACM Computing Surveys*, 41(3), 1-58. <https://doi.org/10.1145/1541880.1541882>
- [5]. FastAPI Documentation. (2024). *FastAPI - Modern, fast web framework for building APIs*. <https://fastapi.tiangolo.com/>
- [6]. Goldstein, M., & Uchida, S. (2016). A comparative evaluation of unsupervised anomaly detection algorithms for multivariate data. *PLOS ONE*, 11(4), e0152173. <https://doi.org/10.1371/journal.pone.0152173>
- [7]. LangChain Documentation. (2024). *LangChain: Building applications with LLMs*. <https://python.langchain.com/>
- [8]. Liu, F. T., Ting, K. M., & Zhou, Z.-H. (2008). Isolation forest. *2008 Eighth IEEE International Conference on Data Mining*, 413–422. <https://doi.org/10.1109/ICDM.2008.17>
- [9]. Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- [10]. Ramaswamy, S., Rastogi, R., & Shim, K. (2000). Efficient algorithms for mining outliers from large data sets. *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*, 427–438. <https://doi.org/10.1145/342009.335437>
- [11]. Székely, G. J., & Rizzo, M. L. (2013). Energy statistics: A class of statistics based on distances. *Journal of Statistical Planning and Inference*, 143(8), 1249–1272. <https://doi.org/10.1016/j.jspi.2013.03.018>.